Análisis EDA de la cafetería: proyecto de clase

Kevin Nicolas Álzate Orjuela

Ficha 3533558

Servicio Nacional de Aprendizaje (SENA)

Técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial

Dra. Natalia Vargas

27 de octubre de 2026

Tabla de contenido

2.1 Actividades de reflexión inicial 3

2.2 Actividades de contextualización e identificación de conocimiento 5

2.3 Actividades de apropiación 5

2.4 Actividades de transferencia del conocimiento 8

2.4.1 Importación de la base de datos y normalización 8

2.4.2 Producto más vendido y participación en las ventas 12

2.4.3 Producto más vendido por ubicación 15

2.4.4 Método de pago más utilizado por mes 17

Conclusiones ..... **¡Error! Marcador no definido.**

Referencias 21

Análisis EDA de la cafetería: proyecto de clase

2.1 Actividades de reflexión inicial

A continuación, se responden las preguntas de reflexión propuestas en la guía, relacionando cada respuesta con la importancia de comprender y validar los datos antes de analizarlos.

1. Si un error tan "básico" como no revisar las unidades de medida destruyó un proyecto de 125 millones de dólares en la NASA, ¿qué consecuencias podría tener para una empresa actual procesar un archivo de Excel sin saber si la columna "Ventas" está en pesos colombianos, ¿dólares o euros?

Una empresa que vende a nivel internacional y necesita hacer conversiones para proyecciones, estados financieros o informes de resultados podría ver alteradas sus métricas generales si recibe un dato tan importante sin saber su moneda. Es el mismo error de la sonda: así como la NASA interpretó unidades inglesas (libras-fuerza) como si fueran métricas (newtons) (Mars Climate Orbiter Mishap Investigation Board [MCOMIB], 1999), la empresa podría tomar 10 USD como 10 COP, con una diferencia de miles de veces. Además, si se quiere determinar la participación de un producto dentro de las ventas totales y no está claro en qué moneda están, los porcentajes serían falsos. Esto llevaría a decisiones erradas sobre precios, inversión y metas, e incluso a alterar la producción, por ejemplo, al planear compras o inventario con base en ventas mal interpretadas.

2. Teniendo en cuenta el caso de la sonda espacial, ¿por qué cree que la Ficha de caracterización de variables (Diccionario de datos) es el paso más importante antes de empezar a escribir código en Python o SQL?

El diccionario de datos es de lo más importante al manejar una base de datos, porque muchas veces la información la comparten distintas personas u organizaciones. Documenta el nombre de cada columna, su tipo de dato, unidad de medida, significado y valores permitidos, lo que da claridad sobre qué se puede hacer con la base si alguien la ve por primera vez. Debe hacerse antes de escribir código porque, sin saber qué es cada variable, no se puede asignar su tipo, limpiarla ni aplicar transformaciones válidas. En el caso de la sonda, cada equipo asumió algo distinto sobre las unidades; un diccionario compartido habría evitado ese supuesto (MCOMIB, 1999).

3. Si mañana llega a su primer trabajo y el gerente le entrega un archivo (.csv, .xlsx, .json) lleno de números sin ninguna explicación (sin metadatos), ¿cuál debería ser su primera acción como analista de datos antes de aplicar cálculos o transformaciones?

Lo primero sería pedir información a quien generó el archivo o al gerente (qué significa cada columna, sus unidades y su origen) para mejorar la comprensión. Si no es posible, realizaría un diccionario de datos y un diagnóstico general de cada variable (tipos, nulos, duplicados, rangos y valores atípicos), además de cómo se relacionan entre sí. No aplicaría cálculos ni transformaciones hasta entender los datos, y documentaría las suposiciones que haga, para no repetir el error de asumir unidades sin verificar.

4. Hoy en día existe una obsesión por tener "Big Data" (millones de registros). A partir del caso de estudio, ¿de qué sirve tener millones de datos y las mejores herramientas, si se comete un fallo en la etapa de comprensión estructural del dato?

No sirve de nada, porque con datos mal comprendidos las transformaciones, limpiezas y predicciones podrían ser erróneas, alterando los análisis univariados, bivariados y multivariados y también las conclusiones. Es el principio de "basura entra, basura sale": con millones de registros el error se multiplica a gran escala, y las mejores herramientas solo lo calculan más rápido. La NASA tenía ingenieros y tecnología de primer nivel, pero falló en la comprensión de un dato básico. La calidad y la comprensión estructural del dato importan más que su cantidad.

2.2 Actividades de contextualización e identificación de conocimiento

Las preguntas de negocio que se resuelven en este análisis son las siguientes:

1. ¿Cuál fue el producto con el valor más alto dentro de las ventas?
2. ¿Cuál fue el método de pago más utilizado por los usuarios en cada uno de los meses?
3. ¿Cómo se comportaron las ventas durante el periodo seleccionado en cada punto de venta?

2.3 Actividades de apropiación

La base de datos seleccionada para realizar este análisis fue extraída de Kaggle (Mohamed, s. f.). Principalmente describe las ventas realizadas por una cafetería entre el 1 de enero de 2023 y el 31 de diciembre de 2023. Se identifican variables como id_transaccion (Transaction ID), productos (Item), cantidad (Quantity), precio por unidad (Price Per Unit), total vendido (Total Spent), método de pago (Payment Method), locación (Location) y fecha de la transacción (Transaction Date). En la Tabla 1 se presenta el diccionario de datos de la base.

Al generar un diagnóstico inicial se encontraron datos nulos y sucios, a los cuales se les realizó una transformación. En el caso de algunas columnas, como item, precio por unidad, total vendido y cantidad, se podían inferir datos por naturalidad, ya que el nombre del ítem se podía deducir a partir del precio unitario, las cantidades vendidas se calculaban dividiendo el total vendido entre el precio unitario, el precio unitario dividiendo el total entre las unidades vendidas y el total multiplicando las cantidades vendidas por el precio unitario. Esto permitió recuperar una gran cantidad de datos nulos y sucios. Para las columnas restantes era un poco más complicado, ya que con locación y fecha este mismo análisis no era posible; aun así, no se eliminaron registros, porque podría alterar el análisis.

Tabla 1

Diccionario de datos de la base Cafe Sales

Variable	Descripción	Tipo estadístico	Tipo técnico (Python)	Valores permitidos / formato	Observaciones de calidad
Transaction ID	Identificador único de cada transacción (compra) registrada.	Cualitativa nominal	string (object)	Formato TXN_ seguido de 7 dígitos (ej. TXN_1961373). Sin valores repetidos.	Llave primaria de la tabla; no se usa en cálculos.
Item	Producto vendido en la transacción.	Cualitativa nominal	string (object)	8 categorías: Cake (pastel), Coffee (café), Cookie (galleta), Juice (jugo), Salad (ensalada), Sandwich (sándwich), Smoothie (batido) y Tea (té).	Contiene datos faltantes y los marcadores UNKNOWN y ERROR.
Quantity	Número de unidades del producto vendidas en la transacción.	Cuantitativa discreta	integer (int64)	Enteros de 1 a 5. Unidad de medida: unidades.	Contiene faltantes, UNKNOWN y ERROR; por eso se carga como texto y debe convertirse a numérico.
Price Per Unit	Precio de venta de una unidad del producto.	Cuantitativa continua	float (float64)	Valor fijo por producto: Cookie 1.0, Tea 1.5, Coffee 2.0, Cake 3.0, Juice 3.0, Sandwich 4.0, Smoothie 4.0, Salad 5.0. La fuente no especifica la moneda.	Puede deducirse a partir de Item. Contiene faltantes, UNKNOWN y ERROR.
Total Spent	Valor total de la transacción.	Cuantitativa continua	float (float64)	Quantity × Price Per Unit. Rango de 1.0 a 25.0. La fuente no especifica la moneda.	Se puede recalcular para validar o recuperar valores faltantes. Contiene faltantes, UNKNOWN y ERROR.
Payment Method	Método con el que el cliente pagó la transacción.	Cualitativa nominal	string (object)	3 categorías: Cash (efectivo), Credit Card (tarjeta de crédito) y Digital Wallet (billetera digital).	Contiene faltantes, UNKNOWN y ERROR.
Location	Modalidad en la que se realizó la compra.	Cualitativa nominal	string (object)	2 categorías: In-store (en tienda) y Takeaway (para llevar).	Contiene faltantes, UNKNOWN y ERROR.
Transaction Date	Fecha en la que se realizó la transacción.	Variable temporal	datetime (datetime64)	Formato AAAA-MM-DD. Rango: 2023-01-01 a 2023-12-31 (un año).	Se carga como texto; debe convertirse a fecha. Contiene faltantes, UNKNOWN y ERROR.

Nota. Los valores faltantes y los marcadores de error (UNKNOWN, celdas vacías, formato de fechas, etc.) fueron depurados y tratados previamente en Python con librerías como Pandas. Una vez normalizados y limpios los datos, se importaron y estructuraron en MySQL Workbench para garantizar la integridad y confiabilidad de las consultas de negocio. Elaboración propia.(valores en **dólares estadounidenses (USD).**

2.4 Actividades de transferencia del conocimiento

En esta sección se explican la importación y la normalización de la base de datos en MySQL Workbench, y las consultas SQL con las que se responden las preguntas de negocio.

2.4.1 Importación de la base de datos y normalización

Como se observa en la Figura 1, es necesario normalizar los datos. Inicialmente no se contemplaba hacerlo, pero como el ejercicio requiere joins se decidió normalizar la tabla, además de que el modelo queda mucho más optimizado al momento de modificar, consultar o transformar los datos.

Figura 1

Tabla `sales_coffe` *original, sin normalizar*

Transaction_ID	Item	Quantity	Price_Per_Unit	Total_Spent	Payment_Method	Location	Transaction_Date
TXN_1000555	Tea	1.0	1.50	1.50	Credit Card	In-store	2023-10-19
TXN_1002457	Cookie	5.0	1.00	5.00	Digital Wallet	Takeaway	2023-09-29
TXN_1003246	Juice	2.0	3.00	6.00	Unknow	Unknow	2023-02-15
TXN_1004184	Smoothie	1.0	4.00	4.00	Credit Card	In-store	2023-05-18
TXN_1004563	Tea	5.0	1.50	7.50	Credit Card	In-store	2023-10-28
TXN_1005331	Coffee	1.0	2.00	2.00	Digital Wallet	Takeaway	2023-11-04
TXN_1005377	Cake	5.0	3.00	15.00	Digital Wallet	Takeaway	2023-06-03
TXN_1005472	Coffee	4.0	2.00	8.00	Credit Card	Unknow	2023-04-21
TXN_1006942	Salad	1.0	5.00	5.00	Credit Card	In-store	2023-11-30
TXN_1007347	Salad	4.0	5.00	20.00	Digital Wallet	In-store	2023-08-28
TXN_1009421	Cookie	4.0	1.00	4.00	Cash	Takeaway	2023-02-21
TXN_1010950	Cookie	1.0	1.00	1.00	Digital Wallet	Takeaway	2023-01-07
TXN_1011236	Cake	1.0	3.00	3.00	Cash	In-store	2023-02-08
TXN_1012349	Cake	4.0	3.00	12.00	Cash	In-store	2023-07-08
TXN_1015883	Cookie	4.0	1.00	4.00	Cash	In-store	2023-10-16
TXN_1016246	Coffee	1.0	2.00	2.00	Unknow	Unknow	2023-01-19
TXN_1018470	Juice	3.0	3.00	9.00	Unknow	Unknow	2023-01-14
TXN_1018880	Smoothie	5.0	4.00	20.00	Digital Wallet	Unknow	2023-07-15
TXN_1020478	Coffee	1.0	2.00	2.00	Digital Wallet	Takeaway	2023-03-09

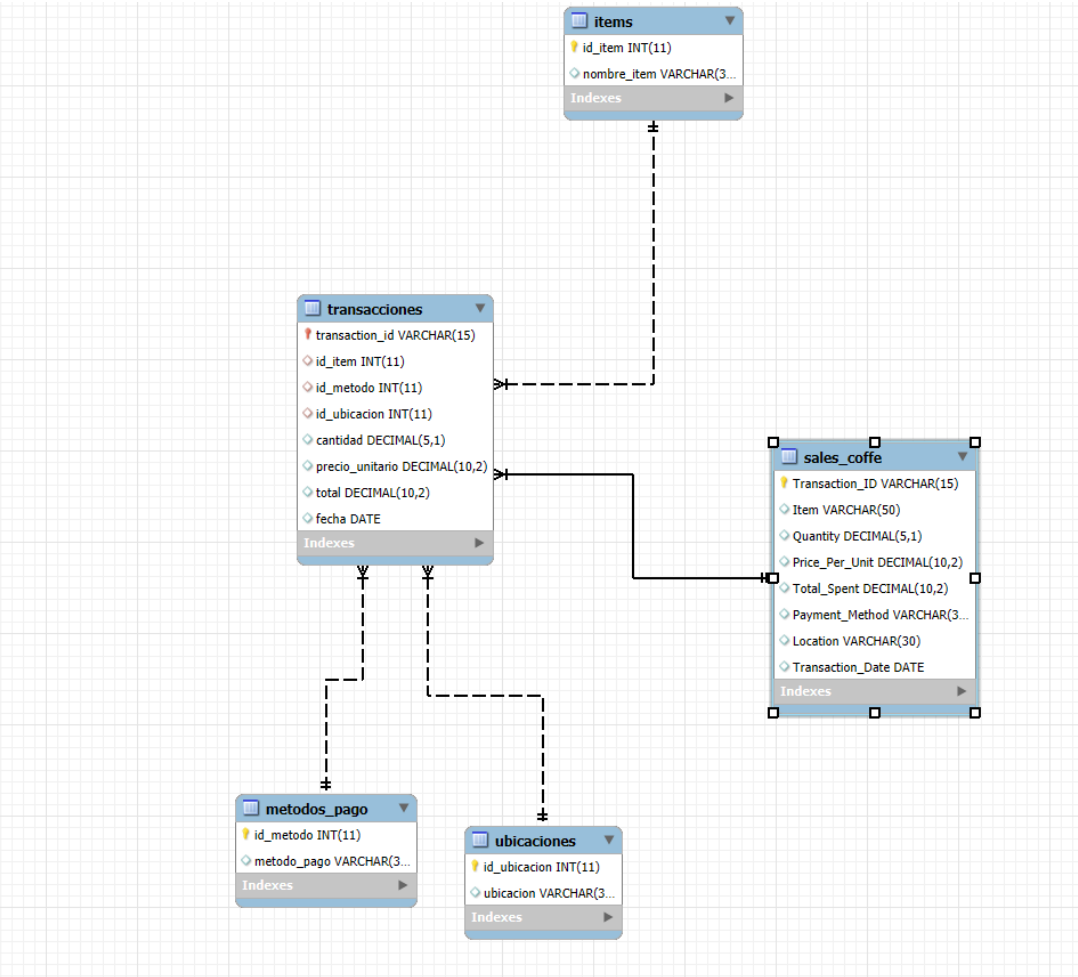
Nota. Captura de pantalla de MySQL Workbench. Elaboración propia.

La Figura 2 presenta el modelo entidad-relación, con la cardinalidad de cada tabla y sus atributos:

- `items` 1-N `transacciones`
- `sales_coffe` 1-N `transacciones`
- `metodos_pago` 1-N `transacciones`
- `ubicaciones` 1-N `transacciones`

Figura 2

Modelo entidad-relación de la base de datos de la cafetería



Nota. Diagrama elaborado en MySQL Workbench. Elaboración propia.

Primero se creó la base de datos donde se va a guardar el archivo de la cafetería ya limpio (Figura 3).

Figura 3

Creación de la base de datos

```
create database sales_coffe;
```

Nota. Captura de pantalla de MySQL Workbench. Elaboración propia.

Posteriormente se creó la tabla para que los campos ya estuvieran definidos antes de importar el archivo y no se generara ningún error (Figura 4).

Figura 4

Creación de la tabla `sales_coffe`

```
CREATE TABLE sales_coffe (
    Transaction_ID VARCHAR(15) PRIMARY KEY,
    Item VARCHAR(50),
    Quantity DECIMAL(5,1),
    Price_Per_Unit DECIMAL(10,2),
    Total_Spent DECIMAL(10,2),
    Payment_Method VARCHAR(30),
    Location VARCHAR(30),
    Transaction_Date DATE
);
```

Nota. Captura de pantalla de MySQL Workbench. Elaboración propia.

Con los datos ya importados mediante el Wizard, se empezó a normalizar la tabla con el fin de evitar duplicados, eliminar la redundancia de datos y evitar anomalías durante las operaciones de inserción, actualización y eliminación. Para ello se crearon tres tablas adicionales, en las que a cada ítem, ubicación y método de pago se le asignó un identificador único, y se extrajeron los datos de la tabla original (Figura 5).

Figura 5

Creación de las tablas `items`, `metodos_pago` *y* `ubicaciones`

```
CREATE TABLE items (
    id_item INT AUTO_INCREMENT PRIMARY KEY,
    nombre_item VARCHAR(30) UNIQUE
);
INSERT INTO items (nombre_item)
SELECT DISTINCT Item FROM sales_coffe;

CREATE TABLE metodos_pago (
    id_metodo INT AUTO_INCREMENT PRIMARY KEY,
    metodo_pago VARCHAR(30) UNIQUE
);
INSERT INTO metodos_pago (metodo_pago)
SELECT DISTINCT payment_Method FROM sales_coffe;


CREATE TABLE ubicaciones (
    id_ubicacion INT AUTO_INCREMENT PRIMARY KEY,
    ubicacion VARCHAR(30) UNIQUE
);
INSERT INTO ubicaciones (ubicacion)
SELECT DISTINCT `Location` FROM sales_coffe;
```

Nota. Capturas de pantalla de MySQL Workbench. Elaboración propia.

Posteriormente se creó la tabla `transacciones` y se cargaron en ella los datos, con el fin de dar respuesta a las preguntas de negocio (Figura 6).

Figura 6

Creación y carga de la tabla `transacciones`

```
#creamos la tabla puente
CREATE TABLE transacciones (
    transaction_id VARCHAR(15) PRIMARY KEY,
    id_item INT,
    id_metodo INT,
    id_ubicacion INT,
    cantidad DECIMAL(5,1),
    precio_unitario DECIMAL(10,2),
    total DECIMAL(10,2),
    fecha DATE,
    FOREIGN KEY (id_item) REFERENCES items(id_item),
    FOREIGN KEY (id_metodo) REFERENCES metodos_pago(id_metodo),
    FOREIGN KEY (id_ubicacion) REFERENCES ubicaciones(id_ubicacion)
);

INSERT INTO transacciones
SELECT s.Transaction_ID, i.id_item, m.id_metodo, u.id_ubicacion,
       s.Quantity, s.Price_Per_Unit, s.Total_Spent, s.Transaction_Date
FROM sales_coffe s
JOIN items i ON s.Item = i.nombre_item
JOIN metodos_pago m ON s.Payment_Method = m.metodo_pago
JOIN ubicaciones u ON s.Location = u.ubicacion;
```

Nota. Capturas de pantalla de MySQL Workbench. Elaboración propia.

2.4.2 Producto con mayor valor total y participación en las ventas

1. ¿Cuál fue el producto con el valor más alto dentro de las ventas?

La ensalada (Salad) es el producto estrella de la cafetería, con el 21,49 % de las ventas totales, seguida de los smoothies (18,21 %) y los sándwiches (15,35 %), que son los que tienen la participación más elevada dentro de las ventas totales (Figura 7). Sin embargo hay que aclarar

que por volumen los pasteles y smoothies son lo que mayor volumen en cuanto a unidades vendidas poseen.

Figura 7

Consulta y resultado de las ventas y la participación por producto

```
SELECT i.nombre_item, SUM(t.total) AS ventas,
   ROUND(SUM(t.total) * 100.0 /(SELECT SUM(total) FROM transacciones),2) AS porcentaje_participacion
FROM transacciones t
JOIN items i ON t.id_item = i.id_item
GROUP BY i.nombre_item
ORDER BY ventas DESC;
```

nombre_item	ventas	porcentaje_participacion
Salad	18190.00	21.49
Smoothie	15412.00	18.21
Sandwich	12996.00	15.35
Cake	11958.00	14.13
Juice	10017.00	11.83
Coffee	7518.00	8.88
Tea	5136.00	6.07
Cookie	3416.00	4.04

```
SELECT i.nombre_item,
       SUM(t.cantidad)        AS unidades_vendidas,
       MAX(t.precio_unitario) AS precio_unitario
FROM transacciones t
JOIN items i ON t.id_item = i.id_item
GROUP BY i.nombre_item
ORDER BY unidades_vendidas DESC;
```

nombre_item	unidades_vendidas	precio_unitario
Cake	3986.0	3.00
Smoothie	3853.0	4.00
Coffee	3759.0	2.00
Salad	3638.0	5.00
Tea	3424.0	1.50
Cookie	3416.0	1.00
Juice	3339.0	3.00
Sandwich	3249.0	4.00

Nota. Capturas de pantalla de MySQL Workbench. Elaboración propia.

2.4.3 Producto más vendido por ubicación

¿Cuál fue el producto más vendido por ubicación?

En esta consulta se identifican las ventas totales de cada producto según la ubicación (Figura 8). La ensalada es el producto con mayor demanda por parte de los clientes de este establecimiento, sin importar si la compra es para llevar (Takeaway), en tienda (In-store) o de ubicación desconocida (Unknow).

Figura 8

Consulta y resultado de las ventas por producto y ubicación

```
SELECT u.ubicacion, i.nombre_item, SUM(t.total) AS ventas,
       ROW_NUMBER() OVER (PARTITION BY u.ubicacion ORDER BY SUM(t.total) DESC) AS Ranking
FROM transacciones t
JOIN ubicaciones u ON t.id_ubicacion = u.id_ubicacion
JOIN items i ON t.id_item = i.id_item
GROUP BY u.ubicacion, i.nombre_item
ORDER BY u.ubicacion, ventas DESC;
```

ubicacion	nombre_item	ventas	Ranking
In-store	Salad	5810.00	1
In-store	Sandwich	4332.00	2
In-store	Smoothie	4268.00	3
In-store	Cake	3522.00	4
In-store	Juice	3168.00	5
In-store	Coffee	2066.00	6
In-store	Tea	1582.50	7
In-store	Cookie	1036.00	8
Takeaway	Salad	5445.00	1
Takeaway	Smoothie	4380.00	2
Takeaway	Sandwich	3916.00	3
Takeaway	Cake	3702.00	4
Takeaway	Juice	2772.00	5
Takeaway	Coffee	2334.00	6
Takeaway	Tea	1570.50	7
Takeaway	Cookie	1168.00	8
Unknow	Salad	6935.00	1
Unknow	Smoothie	6764.00	2
Unknow	Sandwich	4748.00	3
Unknow	Cake	4734.00	4
Unknow	Juice	4077.00	5
Unknow	Coffee	3118.00	6
Unknow	Tea	1983.00	7
Unknow	Cookie	1212.00	8

Nota. Capturas de pantalla de MySQL Workbench. Elaboración propia.

2.4.4 Método de pago más utilizado por mes

¿Cuál fue el método de pago más utilizado en cada uno de los meses?

En la consulta se seleccionaron los métodos de pago más usados por los clientes en cada mes del año, ordenados según el valor de las ventas (Figura 9). En la figura se muestran los resultados de enero, octubre, noviembre y diciembre. En esos cuatro meses el primer lugar lo ocupa la categoría Unknow, es decir, los pagos sin método registrado. No se mostraron los meses restantes debido a la extensión de la tabla. Pero los métodos de pagos desconocidos poseen un gran volumen dentro de nuestra base de datos. Debe ser prioridad para la empresa registrar esos datos con éxito en análisis posteriores o recuperarlos con información histórica.

Figura 9

Consulta y resultado del método de pago por mes

```sql
SELECT v.mes, v.metodo_pago,v.ventas,
      ROW_NUMBER() OVER (PARTITION BY v.mes ORDER BY v.ventas DESC) AS ranking
FROM (SELECT
        DATE_FORMAT(t.fecha, '%Y-%m') AS mes,
        m.metodo_pago,
        SUM(t.total) AS ventas
    FROM transacciones t
    JOIN metodos_pago m
        ON t.id_metodo = m.id_metodo
    GROUP BY
        DATE_FORMAT(t.fecha, '%Y-%m'),
        m.metodo_pago) AS v
ORDER BY v.mes, ranking;
```

2023-01	Unknow	2170.50	1
2023-01	Credit Card	1773.50	2
2023-01	Cash	1704.50	3
2023-01	Digital Wallet	1570.50	4
2023-10	Unknow	2306.00	1
2023-10	Digital Wallet	1853.00	2
2023-10	Cash	1655.50	3
2023-10	Credit Card	1480.50	4
2023-11	Unknow	2003.00	1
2023-11	Digital Wallet	1808.50	2
2023-11	Cash	1620.50	3
2023-11	Credit Card	1525.00	4
2023-12	Unknow	2172.00	1
2023-12	Credit Card	1708.50	2
2023-12	Digital Wallet	1683.00	3
2023-12	Cash	1589.50	4

Nota. Capturas de pantalla de MySQL Workbench. Elaboración propia.

Conclusiones

A partir del desarrollo de este proyecto de análisis exploratorio de datos, se pueden extraer las siguientes conclusiones, organizadas en tres ejes fundamentales:

1. Hallazgos Clave del Negocio

El análisis de las ventas de la cafetería durante el año 2023 permite identificar una clara tendencia hacia el consumo de productos saludables. La **Ensalada (Salad)** se consolidó como el producto estrella, generando el 21,49 % de los ingresos totales, seguida de los smoothies (18,21 %) y los sándwiches (15,35 %). Sin embargo, al analizar el volumen de unidades vendidas, los productos líderes son los pasteles y los smoothies, lo que indica que existe una diferencia entre los productos de mayor rotación y los de mayor rentabilidad. Esta información es crucial para optimizar las estrategias de marketing, ajustar la oferta a la demanda y diseñar promociones que impulsen la venta de los productos más rentables.

2. El Principal Desafío: La Calidad de los Datos

El hallazgo más crítico del proyecto es la alta proporción de datos desconocidos, estandarizados como "Unknown", en las variables de método de pago (25,79 %) y ubicación (32,65 %). Este problema tiene un impacto directo en la capacidad del negocio para tomar decisiones informadas. En el caso de los métodos de pago, la falta de registros precisos impide realizar conciliaciones bancarias confiables y entender el comportamiento financiero de los clientes. En cuanto a la ubicación, la ausencia de datos dificulta la optimización de la logística, la asignación de personal y la comprensión de las preferencias de consumo (en tienda vs. para llevar). Ignorar esta deficiencia podría distorsionar la contabilidad y restar precisión a futuras proyecciones financieras.

3. Recomendaciones Estratégicas

Con base en los hallazgos anteriores, se recomienda a la empresa implementar las siguientes acciones:

- **Fortalecer la captura de datos:** Es prioritario mejorar los procesos de registro en el punto de venta para reducir la cantidad de transacciones con datos faltantes o desconocidos. Esto podría incluir la obligatoriedad de registrar el método de pago y la ubicación, o la implementación de un sistema de incentivos para los empleados.
- **Enfocar el marketing en productos saludables:** Dado el éxito de la ensalada y los smoothies, se sugiere desarrollar campañas de marketing que destaquen estos productos, aprovechando la tendencia del consumidor hacia opciones más saludables.
- **Análisis de estacionalidad:** Se recomienda realizar un análisis más profundo de las series de tiempo para identificar patrones estacionales en las ventas de productos específicos (por ejemplo, el consumo de café o té en meses fríos), lo que permitiría ajustar el inventario y las promociones de manera más efectiva.

4. Reflexión sobre el Proceso de Análisis

Este proyecto evidenció la importancia de un análisis exploratorio de datos (EDA) riguroso y de una limpieza de datos inteligente. La decisión de imputar datos faltantes utilizando relaciones lógicas (por ejemplo, deducir el ítem a partir del precio unitario) permitió recuperar una cantidad significativa de registros que de otro modo se habrían perdido. Asimismo, la normalización de la base de datos en MySQL no solo optimizó el rendimiento de las consultas, sino que también garantizó la integridad y confiabilidad de los resultados. La experiencia confirma que la calidad y la comprensión estructural del dato son más importantes que su cantidad, y que un análisis bien fundamentado es la base para cualquier decisión empresarial acertada.

Referencias

Mars Climate Orbiter Mishap Investigation Board. (1999, 10 de noviembre). *Phase I report*. National Aeronautics and Space Administration. https://llis.nasa.gov/llis_lib/pdf/1009464main1_0641-mr.pdf

Mohamed, A. (s. f.). *Cafe sales - Dirty data for cleaning training* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/ahmedmohamed2003/cafe-sales-dirty-data-for-cleaning-training